

Prediksi Saham Menggunakan Recurrent Neural Network (RNN-LSTM) dengan Optimasi Adaptive Moment Estimation

Sio Jurnal Pipin¹, Ronsen Purba^{2,*}, Heru Kurniawan³

¹ Fakultas Informatika, Program Studi Teknologi Informasi, Universitas Mikroskil, Medan, Indonesia

² Fakultas Informatika, Program Studi Magister Teknologi Informasi, Universitas Mikroskil, Medan, Indonesia

³ Fakultas Informatika, Program Studi Teknik Informatika, Universitas Mikroskil, Medan, Indonesia

Email: ¹sio.pipin@mikroskil.ac.id, ^{2,*}ronsen@mikroskil.ac.id, ³heru.kurniawan@mikroskil.ac.id

Correspondence Author Email: ronsen@mikroskil.ac.id

Submitted: 02/08/2023; Accepted: 24/08/2023; Published: 25/08/2023

Abstrak—Prediksi pergerakan harga saham merupakan tantangan kompleks di pasar keuangan karena fluktuasi harga yang sulit diprediksi dan tingkat sensitivitas pergerakan harga yang tinggi. Noise dalam data historis harga saham dan ketergantungan temporal antara harga sebelumnya dan harga saat ini menyulitkan pengenalan pola pergerakan harga. Dalam lingkungan pasar yang dinamis, kemampuan model dalam menghasilkan prediksi yang akurat memiliki implikasi penting bagi pengambilan keputusan investasi yang lebih terinformasi. Model Recurrent Neural Network - Long Short-Term Memory (RNN-LSTM) memiliki potensi besar dalam prediksi harga saham. Model ini mampu menangkap ketergantungan temporal, mengidentifikasi hubungan non-linear, dan mengurai tren kompleks dalam data harga saham. Penelitian ini menerapkan teknik deep learning dengan model RNN-LSTM dengan optimasi Adaptive Moment Estimation (Adam) untuk memprediksi harga saham yang lebih akurat dengan memanfaatkan data historis harga saham dan faktor teknikal. Tahap preprocessing data, termasuk penanganan nilai yang hilang dan normalisasi data, membantu model mengatasi kompleksitas dataset. Hasil pengujian menggunakan metrik Mean Squared Error (MSE) menunjukkan bahwa model mampu menghasilkan prediksi mendekati harga saham aktual dengan nilai loss yang rendah yakni 0109012 dan akurasi nilai prediksi dan aktual yang baik dengan skor Mean Percentage Error (MPE) yaitu 1.74%. Hasil penelitian ini dapat digunakan untuk membantu para investor dan praktisi pasar keuangan dalam menghadapi kompleksitas dan ketidakpastian di pasar saham.

Kata Kunci: Prediksi Harga Saham; Optimasi; LSTM; RNN; Adaptive Moment Estimation

Abstract—Predicting stock price movements is a complex challenge in the financial market due to unpredictable price fluctuations and high sensitivity levels. Noise in historical stock price data and temporal dependencies between previous and current prices make recognizing price movement patterns difficult. In a dynamic market environment, the model's ability to generate accurate predictions holds significant implications for more informed investment decision-making. The Recurrent Neural Network - Long Short-Term Memory (RNN-LSTM) model holds great potential for stock price prediction. It captures temporal dependencies, identifies non-linear relationships, and deciphers complex trends in stock price data. This study employs deep learning techniques with the RNN-LSTM model optimized using Adaptive Moment Estimation (Adam) to enhance stock price prediction accuracy by leveraging historical stock price data and technical factors. Data preprocessing, including handling missing values and data normalization, aids the model in navigating the dataset's intricacies. Test results utilizing the Mean Squared Error (MSE) metric reveal the model's ability to produce predictions that closely resemble actual stock prices, with a low loss value of 0109012. The model also exhibits good predictive accuracy, as evidenced by a favorable Mean Percentage Error (MPE) score of 1.74% between predicted and actual values. These findings hold valuable implications for assisting investors and financial practitioners in managing complexity and uncertainty within the stock market.

Keywords: Stock Price Prediction; Optimization; LSTM; RNN; Adaptive Moment Estimation

1. PENDAHULUAN

Prediksi pergerakan harga saham memiliki tantangan yang kompleks disebabkan faktor-faktor dinamika *closing price* dan tingkat sensitivitas pergerakan harga yang tinggi [1], [2]. Selain fluktuasi harga yang sulit diprediksi, juga terdapat *noise* dalam data historis harga saham dan ketergantungan temporal yang rumit antara harga saham sebelumnya dengan harga saat ini sehingga menyulitkan investor dalam mengenali pola pergerakan harga [3]. Secara umum, prediksi harga saham melibatkan tiga faktor yang secara signifikan mempengaruhi, yaitu faktor teknikal, faktor fundamental, dan faktor sentimen [4]. Analisis teknikal saham memiliki peran krusial dalam membantu para investor dan pelaku pasar mengambil keputusan yang lebih baik di pasar saham yang dinamis. Dalam lingkungan yang penuh dengan fluktuasi harga dan ketidakpastian, analisis teknikal memainkan peran penting dalam mengidentifikasi pola-pola pergerakan harga saham, mengantisipasi tren masa depan, dan mengidentifikasi momen optimal untuk melakukan transaksi jual beli. Analisis teknikal berfokus pada pengamatan data historis harga saham dan volume perdagangan [5]. Banyaknya variabel yang memengaruhi pasar membuat analis dan investor membutuhkan pendekatan yang lebih akurat untuk memprediksi pergerakan harga saham.

Perkembangan kecerdasan buatan, khususnya deep learning, telah menjadi pilihan utama sebagai metode yang sering digunakan untuk meningkatkan prediksi saham [6], [7]. Deep learning menggunakan jaringan saraf buatan untuk memahami pola-pola kompleks dalam data yaitu dengan mengekstrak fitur dari data historis harga saham [8]. Dalam prediksi saham, dataset yang digunakan cenderung kompleks dan volatil sehingga

menyebabkan deep learning lambat dalam konvergensi atau bahkan kegagalan pelatihan secara keseluruhan [9], [10].

Penelitian terdahulu umumnya menggunakan teknik analisis tradisional seperti *Moving Averages*, *Relative Strength Index* yang melibatkan penggunaan grafik dan indikator untuk mengidentifikasi pola dan tren dalam data harga saham [11]. Selain itu, penelitian lain menggunakan teknik ARIMA (*AutoRegressive Integrated Moving Average*) dengan pemodelan berdasarkan data statistik untuk meramalkan data berurutan, termasuk data harga saham. Teknik ini menggabungkan unsur autoregressive (AR) dan moving average (MA) untuk memprediksi pergerakan harga [12]. Sedangkan untuk mengatasi volatilitas dan fluktuasi dalam data harga saham, penelitian terdahulu menggunakan GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*) untuk memperhitungkan ketidakstabilan varians dalam pergerakan harga [13]. Namun, teknik-teknik ini memiliki keterbatasan dalam memahami data kompleks yaitu anomali dalam data harga saham sehingga kesulitan dalam menghasilkan prediksi akurat saat pasar mengalami volatilitas yang tinggi atau pada data berfluktuasi [14].

Penelitian tentang prediksi saham saat ini lebih banyak menggunakan pendekatan dengan teknik *deep learning*, khususnya *Recurrent Neural Network* (RNN) dengan arsitektur *Long Short-Term Memory* (LSTM) [15], [16]. Model *deep learning* mampu memproses volume besar data historis saham dengan lancar, secara otomatis mengekstraksi fitur-fitur yang relevan, dan mengungkap tren non-linear yang sebelumnya sulit diidentifikasi [17]. Dalam penelitian yang dilakukan oleh Zhu Y untuk memprediksi pasar saham perusahaan Apple menggunakan RNN disimpulkan bahwa model ini memiliki keunggulan yang mampu mengolah data time series dengan akurasi prediksi hingga 95% dan *loss* mendekati 0,1% [18]. Penelitian lainnya menggunakan model *deep Recurrent Neural Network* (RNN) yang dapat menerima banyak input dan output berdasarkan jaringan Long Short-Term Memory (LSTM) [19], [20]. Model ini dapat memprediksi *open price*, *lowest price* dan *highest price* suatu saham secara bersamaan dengan akurasi hingga 95% [19]. Hal ini memungkinkan *deep learning* dapat ekstraksi fitur dari dataset saham masa lampau dan dapat menangkap ketergantungan temporal, mengidentifikasi hubungan *non-linear*, dan mengurai tren-tren yang mungkin luput dari metode analisis tradisional [21]. Namun, model *deep learning* tidak terhindar dari risiko terjadinya *vanishing gradient* atau *exploding gradient* saat melatih model yang dalam dan kompleks sehingga dibutuhkan metode optimasi yang dapat mengatasi masalah ini dengan mengatur laju pembelajaran secara adaptif [22].

Perlu adanya optimasi pada model *deep learning* untuk mengoptimalkan proses pelatihan, mempercepat konvergensi, dan meningkatkan kinerja model. Penelitian yang dilakukan oleh Kamalov F et al, menggunakan *single layer* RNN dengan optimasi RMSprop menghasilkan hasil yang optimal dengan validasi dan uji *Mean Absolute Error* masing-masing 0,0150 dan 0,0148 [23]. Penelitian lainnya menggunakan model LSTM dengan membandingkan optimasi *Stochastic Gradient Descent* (SGD) dan *Adaptive Moment Estimation* (Adam) dalam *deep learning* untuk prediksi saham yang menghasilkan *error* yang tidak terlalu signifikan dan sama baiknya dalam optimasi model [2]. Hal ini, pada gilirannya, berkontribusi pada prediksi harga saham yang lebih akurat dalam menangkap pola-pola kompleks dalam data. Optimasi seperti *Adaptive Moment Estimation* (Adam) mampu mengatasi masalah sensitivitas parameter dengan menyesuaikan laju pembelajaran secara adaptif berdasarkan sejarah gradien. Selain itu, fitur adaptif dalam Adam membantu mencegah terjadinya *vanishing gradient* atau *exploding gradient*, memungkinkan model untuk lebih lancar dan stabil dalam proses pembelajarannya [24].

Penelitian ini mengembangkan sebuah model yang mampu meramalkan pergerakan harga saham dengan menggunakan faktor teknikal. Model ini menghasilkan perkiraan prediksi untuk arah pergerakan saham, baik itu beli atau jual. Dataset yang digunakan berasal dari Bursa Efek Indonesia dan mencakup informasi emiten dengan catatan pergerakan harga sejak tanggal 29 Juli 2019. Variabel masukan dalam model ini mencakup tanggal, harga pembukaan, harga penutupan, harga tertinggi, harga terendah, dan volume perdagangan. Pembangunan model dilakukan dengan menggunakan pendekatan pembelajaran mesin berbasis *deep learning*, khususnya model RNN-LSTM, dan proses optimasinya menggunakan metode *Adaptive Moment Estimation* (Adam).

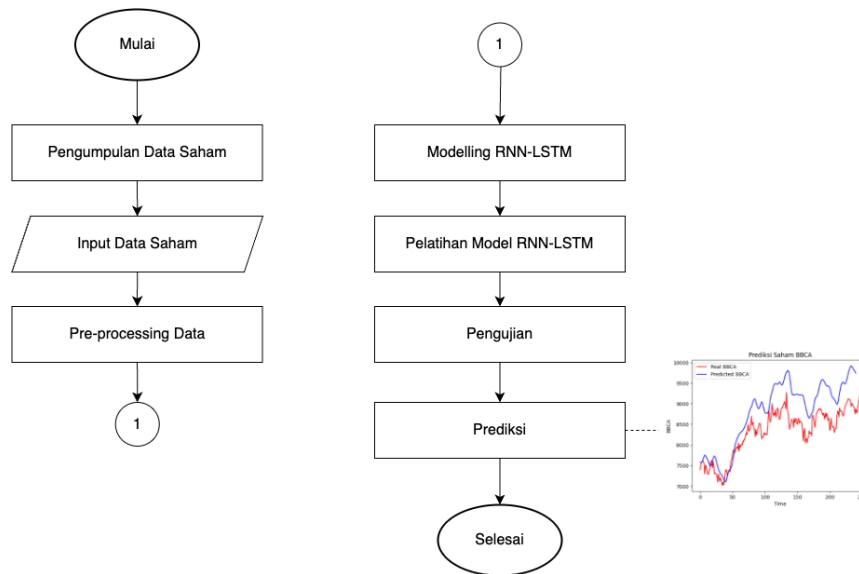
2. METODOLOGI PENELITIAN

2.1 Tahapan Penelitian

Penelitian ini terdiri dari beberapa tahapan yang secara komprehensif membentuk kerangka kerja pengembangan dan penerapan model prediksi saham menggunakan metode *Recurrent Neural Network* (RNN-LSTM) dengan optimasi *Adaptive Moment Estimation* (Adam). Pertama, dilakukan pengumpulan data historis harga saham dan informasi terkait dari sumber data yaitu data pergerakan harga saham tiap harinya di Bursa Efek Indonesia. Data ini meliputi rangkaian harga pembukaan, penutupan, harga tertinggi, harga terendah, dan volume perdagangan. Kemudian, data tersebut mengalami tahap preprocessing untuk membersihkan dan mengolahnya menjadi bentuk yang cocok untuk pelatihan model.

Setelah *preprocessing*, data dibagi menjadi dua *subset*, yaitu data pelatihan dan data pengujian, yang esensial untuk menguji performa model pada data yang tidak digunakan dalam pelatihan. Tahap selanjutnya melibatkan pengembangan model RNN-LSTM yang didesain khusus untuk menangani ketergantungan temporal

dalam data harga saham. Model ini dilatih menggunakan data pelatihan dengan teknik optimasi *Adaptive Moment Estimation* (Adam). Terakhir, dilakukan pengujian kinerja model menggunakan MSE dengan K-Fold 10 seperti ditunjukkan pada gambar 1.



Gambar 1. Diagram Alir Tahapan Penelitian

2.2 Pengumpulan Data Saham

Pengumpulan data historis harga saham diambil dari data pergerakan harga saham tiap harinya di Bursa Efek Indonesia dengan data harian sejak 29 Juli 2019. *Dataset* ini diambil dari situs *kaggle* yaitu <https://www.kaggle.com/datasets/tiwill/saham-idx> yang mencakup kumpulan saham dari 865 saham termasuk 45 saham index LQ45 yang merupakan kumpulan saham dari beberapa perusahaan dengan saham terbaik dan memiliki tingkat likuiditas serta kapitalisasi yang baik [25]. Sumber data yang digunakan dalam penelitian ini yaitu 5 perusahaan yang termasuk dalam saham blue chip Indonesia dengan kode saham BBKA, BBRI, BMRI, ICBP, TLKM, UNVR dengan tiap dataset saham berisi rangkaian variabel seperti tanggal (*Time frame*), harga pembukaan (*Open*), penutupan (*Close*), harga terendah (*Low*), harga tertinggi (*High*), volume perdagangan dan lainnya yang biasa digunakan pada prediksi saham [26]. Namun, enam variabel ini yang diakan digunakan pada tahap berikutnya. Data mentah saham yang berasal dari sumber *dataset* saham IDX seperti ditunjukkan pada tabel 1 berikut.

Tabel 1. Data mentah saham BBKA

Date	Previous	Open price	. . .	non_regular volume	Non_regular frequency
2019-07-29T00:00:00	44800.0	44800.0	. . .	10673483733.0	8.0
2019-07-30T00:00:00	43200.0	43900.0	. . .	35032818040.0	25.0
2019-07-31T00:00:00	43050.0	43000.0	. . .	4376096350.0	15.0
.
.
.
2023-05-23T00:00:00	4420.0	4420.0	. . .	6062541060.0	8.0
2023-05-24T00:00:00	4450.0	4450.0	. . .	976570.0	6.0
2023-05-25T00:00:00	4410.0	4410.0	. . .	1387934.0	9.0

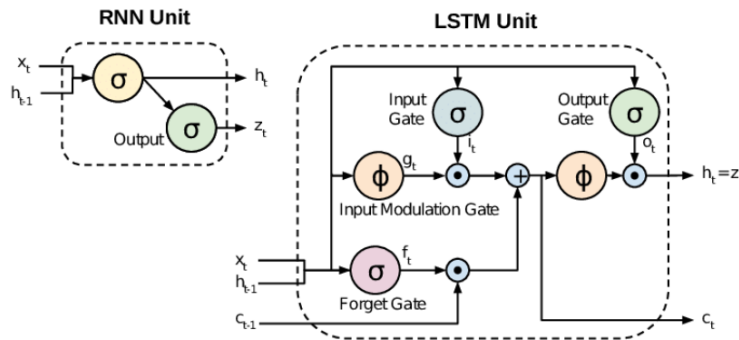
2.3 Pre-processing

Tahapan *preprocessing* pada penelitian ini dilakukan untuk mempersiapkan data harga saham sebelum diolah oleh model prediksi RNN-LSTM. Proses ini melibatkan serangkaian langkah yang dirancang untuk mengoptimalkan kualitas data dan memastikan bahwa data siap digunakan untuk pelatihan dan evaluasi model. Tahapan *preprocessing* data terdiri dari identifikasi dan penanganan terhadap nilai yang hilang atau *missing values* dalam data harga saham. Hal ini terjadi karena adanya jam perdagangan IDX efek bersifat ekuitas di pasar reguler sehingga terdapat hari tertentu yang perdagangan saham ditutup. Penanganan *missing values* ini penting untuk memastikan integritas data [27]. Selanjutnya, normalisasi data dilakukan untuk menjaga skala yang konsisten di semua fitur. Normalisasi yang dilakukan dengan menggunakan teknik seperti *Min-Max Scaling*, yang mengubah nilai-nilai data ke dalam rentang tertentu tanpa mengubah struktur relatif antara data. Setelah itu, data rentang waktu (*time series*) perlu dipertimbangkan. Proses ini mencakup pemilihan rentang waktu yang

sesuai dengan tujuan analisis, baik harian, mingguan, atau *intraday*. Penyesuaian rentang waktu ini penting untuk memahami dan mengeksploitasi karakteristik tren dan pola harga saham.

2.4 Pemodelan RNN-LSTM dengan Optimasi Adaptive Moment Estimation (Adam)

Model *Recurrent Neural Network* (RNN) memiliki kekurangan dalam mengaitkan informasi yang panjang, menyimpulkan masalah hilangnya nilai gradien (*vanishing gradient*) dalam proses perulangan di *neural network* (*back propagation neural network*) [1], [28]. Oleh karena itu digunakan model LSTM untuk mengatasi masalah ini yang berisi rangkaian 4 *gate* dan 5 fungsi aktivasi seperti ditunjukkan pada gambar 2.



Gambar 2. GModel RNN-LSTM

Model RNN-LSTM digunakan untuk prediksi saham memiliki setiap *sequence* didefinisikan sebagai sebuah koleksi *sequential* dari *dataset* setiap perusahaan dalam jangka waktu (N hari). Data harian menggambarkan kinerja saham yang digunakan sebagai urutan fitur pembelajaran dalam *deep learning* seperti *open price*, *close price*, *lowest price*, *higher price* dan *volume*. Model ini dibangun dengan (1) lapisan input layer dengan sejumlah jumlah sel memori sebagai fitur *sequence learning*. *Sequential* yang digunakan yaitu urutan waktu pembukaan saham, diikuti dengan (2) beberapa lapisan LSTM yang digunakan agar model memahami dan dapat mengekstraksi pola-pola temporal yang lebih kompleks dan abstrak dalam data, (3) *denses layer* dengan (4) *output layer* yang berisi sejumlah sel memori sesuai jumlah kategori kinerja *sequence*, terakhir ditambah optimasi *Adaptive Moment Estimation* (Adam) seperti terlihat pada implementasi kode *neural network* menggunakan *library Keras* berikut:

```
regressor= Sequential()
regressor.add(LSTM(units= 64, return_sequences= True, input_shape= (X_train.shape[1],1)))
regressor.add(Dropout(0.25))
regressor.add(LSTM(units= 64, return_sequences= True))
regressor.add(Dropout(0.25))
regressor.add(LSTM(units= 64, return_sequences= True))
regressor.add(Dropout(0.25))
regressor.add(LSTM(units= 64, return_sequences= False))
regressor.add(Dropout(0.25))
regressor.add(Dense(units= 1))
regressor.compile(optimizer= 'adam', loss= 'mean_squared_error')
```

2.5 Pengujian


Pengujian terhadap model prediksi yang dikembangkan dalam penelitian ini dilakukan menggunakan metrik *Mean Squared Error* (MSE) dan *Mean Percentage Error* (MPE). MSE adalah metrik yang umum digunakan dalam tugas regresi untuk mengukur rata-rata selisih kuadrat antara nilai prediksi dan nilai aktual. Sedangkan, MPE merupakan metrik yang mengukur rata-rata persentase perbedaan antara nilai prediksi dan nilai aktual. Dalam konteks prediksi harga saham, MSE memberikan gambaran tentang sejauh mana model mampu menangkap variasi dan besarnya pergerakan harga. Selama tahap pengujian, prediksi model terhadap harga saham dibandingkan dengan harga aktual yang diamati dari *dataset* pengujian. Selisih kuadrat antara harga prediksi dan aktual dihitung untuk setiap titik data. Kemudian, MSE dihitung dengan mengambil rata-rata dari selisih kuadrat tersebut seperti ditunjukkan pada gambar 3. Nilai MSE yang lebih rendah mengindikasikan bahwa prediksi model lebih mendekati harga aktual, mencerminkan kinerja yang lebih baik. Pemilihan MSE sebagai metrik evaluasi dipilih karena kemampuannya dalam memberikan ukuran yang jelas terhadap rata-rata besarnya selisih antara harga saham yang diprediksi dan sebenarnya [29]. MPE akan memberikan informasi tentang seberapa dekat atau jauh prediksi model dari harga aktual dalam bentuk persentase. Jika nilai MPE

positif, itu menunjukkan bahwa prediksi cenderung lebih tinggi dari harga aktual secara rata-rata. Sebaliknya, jika nilai MPE negatif, itu menunjukkan bahwa prediksi cenderung lebih rendah dari harga aktual secara rata-rata [30].

Selama tahap pengujian, prediksi model terhadap harga saham dibandingkan dengan harga aktual yang diamati dari *dataset* pengujian. Selisih kuadrat antara harga prediksi dan aktual dihitung untuk setiap titik data. Kemudian, MSE dihitung dengan mengambil rata-rata dari selisih kuadrat tersebut. Nilai MSE dan MPE yang lebih rendah mengindikasikan bahwa prediksi model lebih mendekati harga aktual, mencerminkan kinerja yang lebih baik.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$\text{MPE} = \frac{100\%}{n} \sum \left(\frac{y - \hat{y}}{y} \right)$$



Gambar 3. Mean Squared Error (MSE) dan Mean Percentage Error (MPE)

3. HASIL DAN PEMBAHASAN

3.1 Hasil Pengumpulan dan Preprocessing Data


Pada tahap awal penelitian, dilakukan pengumpulan data historis harga saham dari data pergerakan harga saham tiap harinya di Bursa Efek Indonesia sejak tahun 29 Juli 2019. Data yang diperoleh mencakup rentang waktu tertentu yang relevan dengan tujuan analisis. Proses pengumpulan data ini memastikan bahwa *dataset* yang digunakan dalam penelitian memiliki integritas dan kualitas yang tinggi. Selanjutnya, tahapan *preprocessing* data dilakukan untuk mempersiapkan data sebelum diolah oleh model RNN-LSTM. Penelitian ini menggunakan data *history* saham dengan kode perusahaan BBKA, BBRI, BMRI, ICBP, TLKM, UNVR dengan tiap dataset saham berisi rangkaian variabel seperti tanggal (*Time frame*), harga pembukaan (*Open*), penutupan (*Close*), harga terendah (*Low*), harga tertinggi (*High*), volume perdagangan.

1. Data saham BBKA

Kode saham BBKA yaitu saham PT Bank Central Asia Tbk dengan data berupa history saham harian sejak 29 Juli 2019 hingga 24 Mei 2022 sebanyak 577 index transaksi yang digunakan sebagai data train seperti terlihat pada tabel 2 dan distribusi berdasarkan time series pada gambar 4.

Tabel 2. Data Saham BBKA

No	Date	Open	High	Low	Close	Volume
1	2019-07-30 0:00:00	31025.0	31250.0	30950.0	31100.0	7645100.0
2	2019-07-31 0:00:00	30950.0	31200.0	30900.0	30950.0	12825800.0
3	2019-08-01 0:00:00	30950.0	31350.0	30925.0	31050.0	15645600.0
4	2019-08-02 0:00:00	30800.0	31025.0	30800.0	30825.0	12597900.0
5	2019-08-05 0:00:00	31075.0	31075.0	30000.0	30000.0	18184800.0
.
.
577	2022-05-24 0:00:00	7325.0	7475.0	7325.0	7350.0	108710800.0




Gambar 4. Grafik Distribusi Saham BBKA

2. Data Saham BBRI

Kode saham BBRI yaitu saham PT Bank Rakyat Indonesia Tbk dengan data berupa history saham harian sejak 29 Juli 2019 hingga 24 Mei 2022 sebanyak 577 index transaksi yang digunakan sebagai data train seperti terlihat pada tabel 3 dan distribusi berdasarkan time series pada gambar 5.

Tabel 3. Data Saham BBRI

No	Date	Open	High	Low	Close	Volume
1	2019-07-29 0:00:00	4480.0	4480.0	4440.0	4460.0	91877000.0
2	2019-07-30 0:00:00	4500.0	4500.0	4460.0	4500.0	68755800.0
3	2019-07-31 0:00:00	4500.0	4510.0	4450.0	4480.0	105834600.0
4	2019-08-01 0:00:00	4490.0	4510.0	4410.0	4450.0	143626600.0
5	2019-07-29 0:00:00	4480.0	4480.0	4440.0	4460.0	91877000.0
.
577	2022-05-24 0:00:00	4320.0	4500.0	4320.0	4460.0	165758600.0


**Gambar 5.** Grafik Distribusi Saham BBRI

3. Data Saham BMRI

Kode saham BMRI yaitu saham PT Bank Mandiri Tbk dengan data berupa history saham harian sejak 29 Juli 2019 hingga 24 Mei 2022 sebanyak 577 index transaksi yang digunakan sebagai data train seperti terlihat pada tabel 4 dan distribusi berdasarkan time series pada gambar 6.

Tabel 4. Data Saham BMRI

No	Date	Open	High	Low	Close	Volume
1	2019-07-29 0:00:00	7825.0	7825.0	7675.0	7800.0	27603200.0
2	2019-07-30 0:00:00	7800.0	7975.0	7725.0	7950.0	43537800.0
3	2019-07-31 0:00:00	7875.0	7975.0	7800.0	7975.0	29504400.0
4	2019-08-01 0:00:00	7875.0	7900.0	7725.0	7775.0	48365500.0
5	2019-08-02 0:00:00	7825.0	7825.0	7675.0	7800.0	27603200.0
.
577	2022-05-24 0:00:00	7950.0	8050.0	7900.0	7925.0	67277500.0


**Gambar 6.** Grafik Distribusi Saham BMRI

4. Data Saham TLKM

Kode saham BMRI yaitu saham PT Telekomunikasi Indonesia Tbk dengan data berupa history saham harian sejak 29 Juli 2019 hingga 24 Mei 2022 sebanyak 577 index transaksi yang digunakan sebagai data train seperti terlihat pada tabel 5 dan distribusi berdasarkan time series pada gambar 7.

Tabel 5. Data Saham TLKM

No	Date	Open	High	Low	Close	Volume
1	2019-07-29 0:00:00	4150.0	4240.0	4140.0	4200.0	54336900.0
2	2019-07-30 0:00:00	4280.0	4300.0	4260.0	4270.0	88417200.0
3	2019-07-31 0:00:00	4240.0	4300.0	4210.0	4300.0	175741000.0
4	2019-08-01 0:00:00	4300.0	4300.0	4260.0	4280.0	94856600.0
5	2019-08-02 0:00:00	4280.0	4300.0	4250.0	4280.0	82253800.0
.
577	2022-05-24 0:00:00	4120.0	4200.0	4120.0	4150.0	151693700.0




Gambar 7. Grafik Distribusi Saham TLKM

5. Data Saham UNVR

Kode saham BMRI yaitu saham PT Unilever Indonesia Tbk dengan data berupa history saham harian sejak 29 Juli 2019 hingga 23 Mei 2022 sebanyak 576 index transaksi yang digunakan sebagai data train seperti terlihat pada tabel 6 dan distribusi berdasarkan time series pada gambar 7.

Tabel 6. Data Saham UNVR

No	Date	Open	High	Low	Close	Volume
1	2019-07-29 0:00:00	44800.0	44825.0	43100.0	43200.0	6052500.0
2	2019-07-30 0:00:00	43900.0	43900.0	42625.0	43050.0	5055500.0
3	2019-07-31 0:00:00	43000.0	43675.0	42675.0	43600.0	5153500.0
4	2019-08-01 0:00:00	43600.0	45850.0	43500.0	45550.0	8440300.0
5	2019-08-02 0:00:00	44750.0	45525.0	44125.0	45000.0	3473300.0
.
577	2022-05-23 0:00:00	5050.0	5075.0	4850.0	4880.0	37184300.0

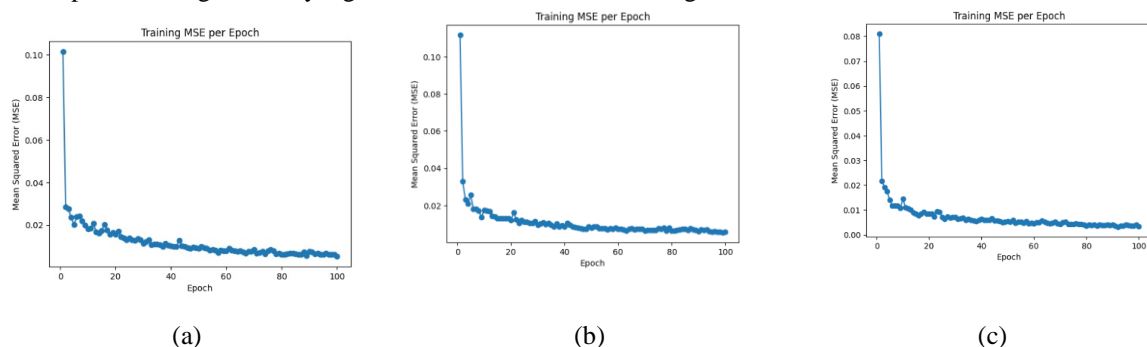


Gambar 8. Grafik Distribusi Saham UNVR

Pada data saham di atas penanganan nilai yang hilang dilakukan dengan menggunakan metode interpolasi data tetangga, sehingga data yang lengkap dapat digunakan dalam analisis. Normalisasi data dilakukan dengan menggunakan teknik *Min-Max Scaling* untuk menjaga skala yang seragam di seluruh fitur.

3.2 Pengujian Model dan Preksi dengan MSE dan MPE

Untuk menguji performa model prediksi saham yang dikembangkan, dilakukan evaluasi menggunakan metrik *Mean Squared Error* (MSE), sedangkan untuk mengukur rata-rata persentase perbedaan antara nilai prediksi dan nilai aktual digunakan *Mean Percentage Error* (MPE). Hasil pengujian menunjukkan bahwa model RNN-LSTM memiliki nilai MSE tertentu pada *dataset* pengujian. Nilai MSE ini mencerminkan tingkat kesalahan rata-rata antara prediksi harga saham yang dihasilkan oleh model dan harga saham aktual.



Gambar 9. Training MSE 100 Epoch (a) BBBCA, (b) BBRI dan (c) BMRI

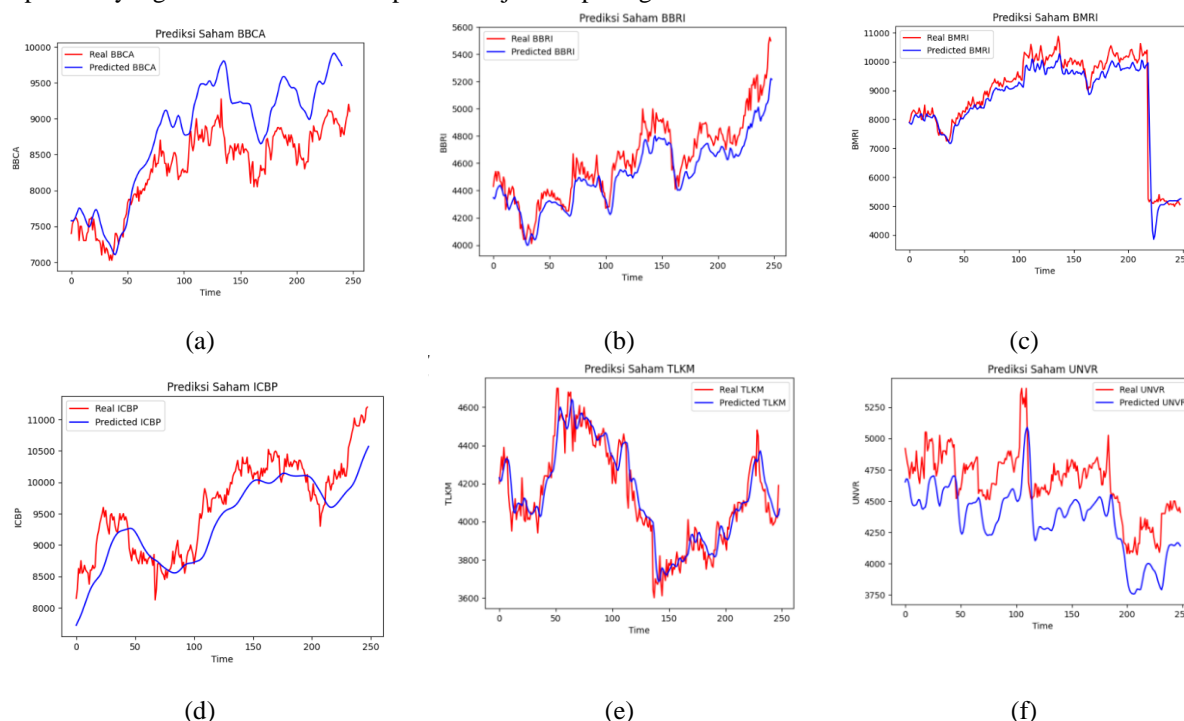
Tabel 7. Perbandingan Nilai MSE dan MPE Pada Model RNN dan RNN-LSTM dengan Jumlah Epoch Berbeda

No.	No. of Epochs	RNN MSE	RNN MPE	RNN-LSTM MSE	RNN-LSTM MPE
1	50	0.1191499	2.98%	0.0145740	1.22%
2	100	0.1150218	3.02%	0.0109012	1.74%
3	200	0.1130403	3.19%	0.0107195	2.46%

No.	No. of Epochs	RNN		RNN-LSTM	
		MSE	MPE	MSE	MPE
4	300	0.1021823	3.78%	0.0103109	2.95%
5	500	0.1001919	3.91%	0.0102117	3.32%

Dari hasil pengujian berdasarkan data saham BBRI seperti ditunjukkan gambar 9 dan tabel 7, ditemukan bahwa model RNN-LSTM memiliki nilai *loss* MSE paling rendah 0.0102117 dengan rata-rata perbedaan antara nilai prediksi dan aktual yaitu 3.32% pada jumlah Epoch 500. Pada setiap iterasi pelatihan yang berbeda ditemukan bahwa nilai MSE rata-rata di bawah 0.01 sehingga perlu mempertimbangkan nilai MPE yang memiliki presentase perbedaan antara nilai prediksi dan aktual yang kecil. Pada pengujian ini menunjukkan bahwa model mampu mendekati harga saham aktual dengan baik sehingga mampu menangkap pola dan tren yang kompleks dalam pergerakan harga saham dengan akurat. Untuk pengujian berikut pada data history saham berbeda digunakan model yang telah dilatih dengan 100 Epoch yaitu pada kode saham BBKA, BBRI, BMRI, ICBP, TLKM, UNVR.

Keberhasilan model dalam menghasilkan prediksi yang mendekati harga saham aktual memberikan implikasi penting dalam pengambilan keputusan investasi. Model ini dapat memberikan pandangan yang lebih baik tentang potensi pergerakan harga saham di masa depan, sehingga membantu investor dalam membuat keputusan yang lebih terinformasi seperti ditunjukkan pada gambar 10.



Gambar 10. Prediksi Saham (a) BBKA (b) BBRI (c) BMRI (d) ICBP (e) TLKM (f) UNVR

Namun demikian, hasil ini juga mengajukan beberapa pertanyaan dan area untuk pengembangan lebih lanjut. Evaluasi lebih lanjut dengan menggunakan metrik lain atau pengujian pada data yang lebih luas dapat membantu memvalidasi keandalan model dalam berbagai skenario pasar. Selain itu, peningkatan performa model melalui penyetelan parameter dan eksplorasi arsitektur yang lebih kompleks dapat menjadi langkah berikutnya dalam pengembangan model prediksi saham yang lebih canggih dan akurat. Dalam keseluruhan, hasil dan pembahasan ini menggambarkan pencapaian awal penelitian ini dalam mengembangkan model prediksi saham menggunakan RNN-LSTM dan evaluasi kinerjanya menggunakan metrik MSE dan MPE. Hasil positif ini memberikan dasar yang kuat untuk penelitian lebih lanjut dalam mengoptimalkan model dan memahami implikasi praktisnya dalam konteks pasar saham.

4. KESIMPULAN

Hasil penelitian ini menunjukkan bahwa model RNN-LSTM memiliki potensi yang signifikan dalam memprediksi pergerakan harga saham. Penggunaan RNN-LSTM dengan optimasi *Adaptive Moment Estimation* (Adam) memungkinkan model untuk menangkap ketergantungan temporal dan hubungan non-linear dalam data harga saham, serta mengurai tren-tren yang kompleks. Dengan melakukan *preprocessing* data yang baik, seperti penanganan nilai yang hilang dan normalisasi data, serta pembagian data train dan test yang proporsional, model berhasil dikembangkan dan melalui pelatihan yang hati-hati, model ini mampu menghasilkan prediksi yang

mendekati harga saham aktual. Pengujian model menggunakan metrik *Mean Squared Error* (MSE) menghasilkan nilai *loss* MSE yang rendah hingga 0.0109012 dan akurasi nilai prediksi dan aktual yang baik dengan skor *Mean Percentage Error* (MPE) yaitu 1.74%, yang menandakan bahwa model mampu mengklasifikasikan pergerakan harga saham dengan tingkat ketepatan yang tinggi. Hal ini memberikan implikasi penting bagi investor dalam membuat keputusan investasi yang lebih terinformasi.

REFERENCES

- [1] W. Hastomo, A. Satyo, B. Karno, N. Kalbuana, E. Nisfiani, and L. ETP -, "Optimasi Deep Learning untuk Prediksi Saham di Masa Pandemi Covid-19," JEPIN (Jurnal Edukasi dan Penelitian Informatika), vol. 7, no. 2, pp. 133–140, 2021.
- [2] M. A. D. Suyudi, E. C. Djamal, and A. Maspupah, "Prediksi Harga Saham Menggunakan Metode Recurrent Neural Network," in Seminar Nasional Aplikasi Teknologi Informasi (SNATi), 2019, pp. 33–38.
- [3] M. Arhami and M. Nasir, Data Mining-Algoritma dan Implementasi. Penerbit Andi, 2020.
- [4] L. Troiano, E. M. Villa, and V. Loia, "Replicating a Trading Strategy by Means of LSTM for Financial Industry Applications," IEEE Trans Industr Inform, vol. 14, no. 7, pp. 3226–3234, Jul. 2018, doi: 10.1109/TII.2018.2811377.
- [5] I. A. El-Khodary, "A Decision Support System for Technical Analysis of Financial Markets Based on the Moving Average Crossover," World Appl Sci J, vol. 6, no. 11, pp. 1457–1472, 2009.
- [6] M. Nabipour, P. Nayyeri, H. Jabani, A. Mosavi, E. Salwana, and S. Shahab, "Deep Learning for Stock Market Prediction," Entropy, vol. 22, no. 8, p. 840, Aug. 2020, doi: 10.3390/E22080840.
- [7] Z. Hu, Y. Zhao, and M. Khushi, "A Survey of Forex and Stock Price Prediction Using Deep Learning," Applied System Innovation, vol. 4, no. 1. MDPI AG, pp. 1–30, Mar. 01, 2021. doi: 10.3390/ASI4010009.
- [8] J. Wang, T. Sun, B. Liu, Y. Cao, and D. Wang, "Financial Markets Prediction with Deep Learning," in Proceedings - 17th IEEE International Conference on Machine Learning and Applications, ICMLA 2018, Institute of Electrical and Electronics Engineers Inc., Jan. 2019, pp. 97–104. doi: 10.1109/ICMLA.2018.00022.
- [9] Y. Mahena, M. Rusli, and E. Winarso, "Prediksi Harga Emas Dunia Sebagai Pendukung Keputusan Investasi Saham Emas Menggunakan Teknik Data Mining," Kalbiscentia J. Sains dan Teknol, vol. 2, no. 1, pp. 36–51, 2015.
- [10] Z. Allen-Zhu, Y. Li, and Z. Song, "A Convergence Theory for Deep Learning via Over-Parameterization," in In International conference on machine learning, 2019, pp. 242–252. [Online]. Available: <https://arxiv.org/abs/1811.03962>.
- [11] Ü. AYCEL and Y. SANTUR, "A New Moving Average Approach to Predict the Direction of Stock Movements in Algorithmic Trading," Journal of New Results in Science, vol. 11, no. 1, pp. 13–25, Apr. 2022, doi: 10.54187/jnrs.979836.
- [12] A. Garlapati, D. R. Krishna, K. Garlapati, N. M. Srikara Yaswanth, U. Rahul, and G. Narayanan, "Stock Price Prediction Using Facebook Prophet and Arima Models," in 6th International Conference for Convergence in Technology, I2CT 2021, Institute of Electrical and Electronics Engineers Inc., Apr. 2021, pp. 1–7. doi: 10.1109/I2CT51068.2021.9418057.
- [13] H. Herwartz, "Stock Return Prediction Under GARCH — An empirical assessment," Int J Forecast, vol. 33, no. 3, pp. 569–580, Jul. 2017, doi: 10.1016/j.ijforecast.2017.01.002.
- [14] Y. Han, K. Yang, and G. Zhou, "A New Anomaly: The Cross-Sectional Profitability of Technical Analysis," Journal of Financial and Quantitative Analysis, vol. 48, no. 5, pp. 1433–1461, 2013, doi: 10.1017/S0022109013000586.
- [15] W. Lu, J. Li, Y. Li, A. Sun, and J. Wang, "A CNN-LSTM-Based Model to Forecast Stock Prices," in Complexity, Hindawi Limited, 2020, pp. 1–10. doi: 10.1155/2020/6622927.
- [16] M. A. Istiaque Sunny, M. M. S. Maswood, and A. G. Alharbi, "Deep Learning-Based Stock Price Prediction Using LSTM and Bi-Directional LSTM Model," in 2nd Novel Intelligent and Leading Emerging Sciences Conference, NILES 2020, Institute of Electrical and Electronics Engineers Inc., Oct. 2020, pp. 87–92. doi: 10.1109/NILES50944.2020.9257950.
- [17] D. W. Jorgenson and M. L. Weitzman, "Can Neural Networks Predict Stock Market?," AC Investment Research Journal, vol. 220, no. 44, 2023.
- [18] Y. Zhu, "Stock Price Prediction Using the RNN Model," J Phys Conf Ser, vol. 1650, no. 3, p. 7, Oct. 2020, doi: 10.1088/1742-6596/1650/3/032103.
- [19] G. Ding and L. Qin, "Study On The Prediction of Stock Price Based on The Associated Network Model of LSTM," International Journal of Machine Learning and Cybernetics, vol. 11, no. 6, pp. 1307–1317, Jun. 2020, doi: 10.1007/s13042-019-01041-1.
- [20] S. J. Pipin and H. Kurniawan, "Analisis Sentimen Kebijakan MBKM Berdasarkan Opini Masyarakat di Twitter Menggunakan LSTM," Jurnal SIFO Mikroskil, vol. 23, no. 2, pp. 197–208, 2022, doi: <https://doi.org/10.55601/jsm.v23i2.900>.

- [21] D. Lien Minh, A. Sadeghi-Niaraki, H. D. Huy, K. Min, and H. Moon, "Deep Learning Approach for Short-Term Stock Trends Prediction Based on Two-Stream Gated Recurrent Unit Network," *IEEE Access*, vol. 6, pp. 55392–55404, Sep. 2018, doi: 10.1109/ACCESS.2018.2868970.
- [22] H. H. Tan and K. H. Lim, "Vanishing Gradient Mitigation with Deep Learning Neural Network Optimization," in *In 2019 7th international conference on smart computing & communications (ICSCC)*, 2019, pp. 1–4.
- [23] F. Kamalov, L. Smail, and I. Gurrib, "Stock Price Forecast With Deep Learning," in *2020 International Conference on Decision Aid Sciences and Application, DASA 2020*, Institute of Electrical and Electronics Engineers Inc., Nov. 2020, pp. 1098–1102. doi: 10.1109/DASA51403.2020.9317260.
- [24] K. K. Chandriah and R. V. Naraganahalli, "RNN / LSTM With Modified Adam Optimizer in Deep Learning Approach for Automobile Spare Parts Demand Forecasting," *Multimed Tools Appl*, vol. 80, no. 17, pp. 26145–26159, Jul. 2021, doi: 10.1007/s11042-021-10913-0.
- [25] K. Stia Rani and N. Nyoman Ayu Diantini, "Pengaruh Kinerja Keuangan Perusahaan Terhadap Harga Saham Dalam Indeks LQ45 Di Bei," vol. 4, no. 6, pp. 1504–1524, 2015.
- [26] D. C. Yıldırım, I. H. Toroslu, and U. Fiore, "Forecasting Directional Movement Of Forex Data Using LSTM with Technical and Macroeconomic Indicators," *Financial Innovation*, vol. 7, no. 1, Dec. 2021, doi: 10.1186/s40854-020-00220-2.
- [27] J. Liu et al., "Innovative Procedures of Data Preparation to Ensure Data Integrity for Crop Modelling," 2020.
- [28] J. Schmidhuber and S. Hochreiter, "Long Short-Term Memory," *Neural Comput*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [29] J. W. Messner, P. Pinson, J. Browell, M. B. Bjerregård, and I. Schicker, "Evaluation of Wind Power Forecasts—An Up-To-Date View," *Wind Energy*, vol. 23, no. 6, pp. 1461–1481, Jun. 2020, doi: 10.1002/we.2497.
- [30] Saigal S and Mehrotra D, "Performance Comparison of Time Series Data Using Predictive Data Mining Techniques Advances in Information Mining," vol. 4, no. 1, pp. 57–66, 2012, [Online]. Available: <http://www.bioinfo.in/contents.php?id=32>